

Проект: Прогнозирование стоимости недвижимости

Общая постановка задачи

Постройте и протестируйте несколько моделей регрессии для прогнозирования цен объекта недвижимости на основе его характеристики, а также разработайте приложение с формой входных данных, дашбордом и справочной информацией.

Этап 1. Исследование данных (EDA)

1.1 Знакомство с данными

- Загрузить набор дат, вывести размерность (число строк/столбцов), определить данные по столбцам.
- Выведите первые/последние строки, выберите случайную строку.
- Описать источник данных, получить критерии измерения, определить целевую переменную (цену).

1.2 Описательная статистика

- Рассчитать базовые статистики для числовых признаков: мин, макс, среднее, медиана, стандартное, квартили.
- Для категориальных признаков — частота категорий, количество уникальных показателей.
- Проверять параметры переменных (цены): гистограмма, точность асимметрии (асимметрии).

1.3 Визуальный анализ

- Гистограммы распределяют ключевые числовые признаки (площадь, количество комнат, годовые постройки и т.д.).
- Диаграммы рассеяния (точечная диаграмма) «признак — цена» для основных признаков.
- Boxplot для восстановления восстановленного по числовому эффекту.
- Тепловая карта корреляций (тепловая карта корреляции) между числовыми внешними и независимыми переменными.
- Проанализируйте категориальные признаки относительно цены (линейчатая диаграмма средних цен по категориям — район, тип дома и т.д.).

1.4 Анализ пропусков и аномалий

- Таблица/визуализация количества и доли пропущенных результатов по каждому столбцу.
- Проверка дубликатов записей.
- Проверка логической согласованности данных (например, отрицательная площадь, нереалистичный год постройки).

1.5 Промежуточные выводы

- Сформулировать 3–5 гипотезу о том, какие признаки сильнее всего влияют на цену, подтвержденные графиками/корреляциями.

Этап 2. Предварительная обработка данных

2.1 Работа с пропусками

- Выбрать и обосновать провал для каждого типа пропусков: удаление строк/столбцов, заполнение медианой/модой, заполнение на основе группировки (например, медиана по району), использование алгоритмов импутации (KNNImputer и т.п.).

2.2 Обработка новой

- Выбрать методы обработки: удаление, винсоризация (ограничение по перцентилам), логарифмирование сильно скошенных признаков.

2.3 Кодирование категориальных признаков

- One-Hot Encoding для номинальных признаков.
- Порядковое/меточное кодирование для рядовых признаков.
- При большом количестве категорий — целевое/среднее кодирование или группировка средних категорий в «прочее».

2.4 Работа с Feature Engineering

- Создание новых признаков (например, «возраст здания» = текущий год – год постройки, «цена за м²», «расстояние до центра»).
- Удаление неинформативных/сильно коррелированных между собой признаков (мультиколлинеарность, VIF).
- При необходимости — уменьшение габаритов.

2.5 Масштабирование признаков

- Обоснование применения StandardScaler / MinMaxScaler / RobustScaler в зависимости от выбранных моделей (для линейных моделей — обязательно, для деревьев — не обязательно).

2.6 Разбиение данных

- Разделение на train/validation/test (например, 70/15/15 или train/test 80/20 с кросс-валидацией).
- Фиксация случайного_состояния для воспроизводимости.
- Проверка на утечку данных (утечку данных): все конвертируются (скалер, кодер) обучаются только на train.

Этап 3. Построение модели регрессии

3.1 Требование: не менее 3 разных моделей

Рекомендуемый набор (выбрать минимум 3, желательно разной природы):

1. **Линейная модель** — Линейная регрессия/Ридж/Лассо/ElasticNet.
2. **Модель на основе деревьев (одиночная)** — Регрессор дерева решений.
3. **Ансамблевая модель (бэггинг)** — Случайный лесной регрессор.
4. **Ансамблевая модель (бустинг)** — Gradient Boosting/XGBoost/LightGBM/CatBoost.
5. **Опционально** — КНН Регрессор, СБР, нейронная сеть (MLPRegressor).

3.2 Обучение и выбор гиперпараметров

- Для каждой модели — базовая версия с параметрами по умолчанию.
- Подбор гиперпараметров: GridSearchCV / RandomizedSearchCV / Optuna с кросс-валидацией на train.
- Фиксация лучших параметров для каждой модели.

3.3 Метрики качества

Рассчитать для каждой модели по валидации/тестированию не менее 3–4 метрик:

- **MAE** (средняя абсолютная ошибка) — средняя абсолютная ошибка в единицах цен.
- **RMSE** (среднеквадратическая ошибка) — чувствительна к большим ошибкам.
- **MAPE** (Mean Absolute Percentage Error) — ошибка в процентах, удобна для обозначения.
- **R²** (коэффициент детерминации) — доля объяснённой дисперсии.
- Опционально: скорректированный R², медианная абсолютная ошибка.

3.4 Сравнение моделей

- Сведите все метрики в единую сравнительную таблицу.
- Постройте график сравнения моделей по метрикам (столбчатая диаграмма).
- Постройте графики «предсказание против факта» (разброс) и график элементов (остатков) для лучшей модели.
- Проанализировать результаты (важность признаков) для деревянных моделей/коэффициенты для линейных.

3.5 Выбор финальной модели

- Обосновать выбор лучшей модели для дальнейшего использования в приложении: не только по метрикам, но и с учетом скорости вывода, интерпретируемости, устойчивости к переобучению.
- Сохраните сохраненную модель и все препроцессоры (скалер, кодер) в файле (pickle/joblib) для использования в приложении.

Этап 4. Применение

4.1 Форма прогноза стоимости

- Интерфейс с полями ввода всех характеристик объекта (площадь, количество комнат, район, этаж, год постройки и т.д.), соответствующий поток обработанной модели.
- Проверка ввода (диапазоны допустимых результатов, обязательные поля).
- Кнопка «Рассчитать» → загрузка сохранённой модели и препроцессоров → вывод прогнозируемой цены.
- Желательно: вывод доверительного интервала прогноза или диапазона (например, $\pm$ MAE), а не только точечного значения.

4.2 Дашборд (отдельная вкладка)

- Ссылка/вкладка на дашборд, отображающий:
 - Общая статистика по датасету (распределения, средние цены по регионам/типам).
 - Интерактивные графики для исследования данных.
 - Сравнение моделей и их метрики.
- Дашборд может быть встроенным (iframe) либо реализован в том же приложении на отдельной вкладке (например, многостраничный Streamlit, Dash, отдельный лист в веб-приложении).

4.3 Справка (Help)

- Отдельная вкладка/раздел с описанием:
 - Что делает приложение и как им пользоваться.
 - Описание входных полей (что означает каждый признак, значение измерения).
 - Краткое описание используемой модели и ее ограничения (на основе имеющихся данных и точности).
 - Контакты/авторство, версия приложения.

4.4 Технические требования к приложению

- Технологический стек на выбор: Streamlit/FastAPI.
 - Загрузка модели должна выполняться один раз при запуске приложения (а не при каждом запросе).
 - Обработка ошибок ввода (некорректированные/пустые значения) с понятными сообщениями пользователя.
-

Критерии оценки результатов

№ Критерий	Требования на «отлично»	Баллы (пример измерения)
1 EDA — полный анализ	Проведен полный анализ структуры, статистик, распределений; выявлены пропуски, выбросы, дубликаты; сформулированы обоснованные выводы/гипотезы	10
2 EDA — визуализация	Использовано ≥ 5 различных типов графиков, информативные графики, подписаны, читаемы	5
3 Предобработка — пропуски и выбросы	Обоснованы и правильно применяются стратегии обработки пропусков и мобильности; отсутствует уничтожение данных	10
4 Предобработка — кодирование и масштабирование	Корректно закодированы категориальные признаки, применено масштабирование там, где это необходимо.	5
5 Разработка функциональных возможностей	Созданы новые содержательные признаки, устранившие мультиколлинеарность	5
6 Количество и разнообразие моделей	Построено ≥ 3 моделей разной природы (линейная, дерево, ансамбль)	10
7 Подбор гиперпараметров	Для моделей выполнен подбор гиперпараметров с кросс-валидацией, а не только базовый уровень	10
8 Метрики качества и их интерпретация	Рассчитаны ≥ 3 метрик для каждой модели, представлена сравнительная таблица/график, дана содержательная интерпретация результатов.	10
9 Обоснование выбора изысканной модели	Аргументированный выбор лучшей модели с учётом метрики и практических соображений	5
10 Приложение — форма прогноза	Форма принимает все нужные параметры, корректно валидирует вводы, дает адекватный прогноз.	10
11 Приложение — дашборд	Дашборд информативен, интерактивен, доступен из приложений (отдельная вкладка/ссылка)	10
12 Приложение — справка	Справка подробного описания функций и ограничений модели.	5

№ Критерий	Требования на «отлично»	Баллы (пример измерения)
13 Исправный код и воспроизводимость	Код структурирован (например, разделение модулей: данные, функции, модели, приложения), есть README, зафиксированы случайные_состояния и версии зависимостей.	5
14 Оформление отчёта/презентации проекта	Логическая структура, выводы на каждом этапе, отсутствие технических ошибок в тексте	5
Итог		100

Дополнительные (бонусные) критерии

- Развёртывание приложения в облаке (Streamlit Cloud, Render, Heroku и т.д.) с публичной ссылкой — +5 баллов.
- Использование продвинутых методов (стекинг моделей, автоматический выбор через Optuna, SHAP-анализ важности признаков) — +5 баллов.
- Использование глобального репозитория — +5 баллов.

Штрафные критерии

- Использование признака, позволяющего определить целевую переменную (утечка данных) — снижение баллов по п.3 и п.8.
- Отсутствие валидации по отложенной выборке (тест, используемый при выборе гиперпараметров) — снижение баллов по п.7.
- Неработающее приложение при сдаче — увеличение снижения баллов по пп.10–12.